

实验一：线性回归算法实验报告说明

本项目实现 OLS、岭回归 (Ridge)、Lasso、LARS 四类线性回归算法，在自构造模拟数据与 Boston 房价数据上完成：探索分析 → 预处理 → 建模 → 评价 → 可视化。

公式怎么看最清晰？

- 推荐用浏览器打开：[docs/公式手册.html](#) (MathJax 渲染，公式一定正常)
- 在 Cursor / VS Code 中请开启 Markdown > Math: Enabled, 正文里的公式块使用 $...$
- 正文叙述里的简单符号直接用 Unicode: α 、 β 、 ε 、 R^2 、 $\hat{y}$ 、 β , 避免行内 LaTeX 兼容问题


目录

- 实验目标
- 整体流程
- 算法原理与公式
- 评价指标公式
- 模拟数据设计
- 实验一：模拟数据 EDA (逐图解读)
- 实验二：四算法对比 (逐图解读)
- 实验三：LARS 稳定性 (逐图解读)
- 实验四：Boston EDA (逐图解读)
- 实验五：Boston 建模 (逐图解读)
- 项目结构与运行
- 结论要点

1. 实验目标

编号	目标
1	掌握 OLS、Ridge、Lasso、LARS 的优化目标、解的形式与适用场景
2	构造无噪声 / 有噪声 / 无多重共线性 / 有多重共线性数据，对比算法
3	多次重复实验，分析 LARS 变量选择稳定性及选择前后效果
4	对 Boston 房价做 EDA、预处理、特征工程，并比较四种算法

2. 整体流程



逐步说明

1. **数据**: 生成模拟数据, 或下载并缓存 Boston。
2. **EDA**: 分布、相关、VIF、散点, 确认线性与共线性。
3. **预处理**: 特征标准化; Boston 去封顶、按相关度筛选。
4. **建模**: 同一划分拟合四模型; Ridge / Lasso / LARS 用交叉验证选超参。
5. **评价**: 测试集上计算 R^2 、MSE、MAE、RMSE。
6. **稳定性**: 多次随机划分, 统计 LARS 入选频率与选择前后指标。
7. **出图**: 写入 outputs/figures/, 数值写入 outputs/reports/。

3. 算法原理与公式

设训练集有 n 个样本、 p 个特征。设计矩阵、响应与参数为：

$$X \in \mathbb{R}^{n \times p}, \quad y \in \mathbb{R}^n, \quad \beta \in \mathbb{R}^p.$$

线性模型：

$$y = X\beta + \varepsilon.$$

其中 ε 为误差项。预测值为：

$$\hat{y} = X\hat{\beta}.$$

3.1 普通最小二乘 OLS

优化目标（残差平方和）：

$$\hat{\beta}_{\text{OLS}} = \arg \min_{\beta} \|y - X\beta\|_2^2 = \arg \min_{\beta} \sum_{i=1}^n (y_i - x_i^\top \beta)^2.$$

正规方程与闭式解（当 $X^\top X$ 可逆）：

$$X^\top X \hat{\beta} = X^\top y, \quad \hat{\beta}_{\text{OLS}} = (X^\top X)^{-1} X^\top y.$$

优点	缺点
无偏（Gauss-Markov 条件下 BLUE）	噪声大时方差大
可解释、计算快	多重共线性时 $X^\top X$ 近奇异，系数不稳
无额外超参	高维（ $p \approx n$ 或 $p > n$ ）易过拟合

3.2 岭回归 Ridge (L_2 正则)

优化目标：

$$\hat{\beta}_{\text{Ridge}} = \arg \min_{\beta} \|y - X\beta\|_2^2 + \alpha \|\beta\|_2^2, \quad \alpha > 0.$$

闭式解：

$$\hat{\beta}_{\text{Ridge}} = (X^\top X + \alpha I)^{-1} X^\top y.$$

αI 使矩阵正定，缓解共线性。本实验用 RidgeCV 按验证 MSE 选 α 。

优点	缺点
共线时更稳	只收缩、不稀疏

优点	缺点
易优化	不能硬变量选择
病态问题下预测常更好	需调节 α

3.3 Lasso (L_1 正则)

优化目标：

$$\hat{\beta}_{\text{Lasso}} = \arg \min_{\beta} \|y - X\beta\|_2^2 + \alpha \|\beta\|_1, \quad \|\beta\|_1 = \sum_{j=1}^p |\beta_j|.$$

L_1 约束常使部分系数精确为 0，从而实现变量选择。本实验用 **LassoCV** 选 α 。

优点	缺点
稀疏、可解释	强共线时倾向随机留下一个相关变量
适合含无关特征	α 过大欠拟合，过小接近 OLS
高维可用	一般无闭式解

3.4 LARS (*Least Angle Regression*)

LARS 是前向分段线性路径算法：每一步沿与当前残差“夹角相等”的方向前进。

记活跃集为 $\mathcal{A}$ ，残差为：

$$r = y - X\hat{\beta}.$$

步骤概要：

1. 将与残差相关性最大的变量加入活跃集；
2. 沿等角方向前进；
3. 直到新变量追上，或达到停止条件。

等角方向满足：

$$X_{\mathcal{A}}^{\top} u_{\mathcal{A}} = A_{\mathcal{A}} \mathbf{1}.$$

本实验：先用 **LarsCV**，再对非零个数 k 做网格 CV，取验证误差更优者，避免过稀。

优点	缺点
适合变量选择	选择可能随划分抖动
路径可解释	强相关下不稳定

优点	缺点
高维相对高效	需 CV 决定停止位置

3.5 特征标准化

$$\tilde{x}_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}, \quad \mu_j = \frac{1}{n} \sum_{i=1}^n x_{ij}, \quad \sigma_j = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_{ij} - \mu_j)^2}.$$

标准化后正则对各特征公平。若 y 未标准化，理论斜率在标准化尺度下为：

$$\beta_j^{\text{scaled}} = \beta_j \sigma_j.$$

4. 评价指标公式

设测试集真实值为 y_i ，预测为 $\hat{y}_i$ ，样本数 m ，均值为 $\bar{y}$ 。

决定系数 R^2

$$R^2 = 1 - \frac{\sum_{i=1}^m (y_i - \hat{y}_i)^2}{\sum_{i=1}^m (y_i - \bar{y})^2}.$$

越接近 1 越好；可以为负。

均方误差 MSE

$$MSE = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2.$$

均方根误差 $RMSE$

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2}.$$

与 y 同量纲，便于和噪声标准差对照。

平均绝对误差 MAE

$$\text{MAE} = \frac{1}{m} \sum_{i=1}^m |y_i - \hat{y}_i|.$$

方差膨胀因子 VIF

对第 j 个特征，用其余特征回归得到 R^2_j ，则：

$$\text{VIF}_j = \frac{1}{1 - R^2_j}.$$

经验：VIF < 5 较安全；5 ~ 10 警惕；> 10 共线严重。

5. 模拟数据设计

特征结构（尺度为 1，等价于原稿 100u 再除以 100）：

$$\begin{aligned} x_1, x_2, x_3 &\sim \text{Uniform}(0, 1), \\ x_4 &= 6.7x_1 + 4x_2 + 0.05u, \\ x_5 &= 2.8x_1 + 3.4x_4 + 0.01u. \end{aligned}$$

信号：

$$\begin{aligned} s_1 &= 0.5 + 2x_1 + 0.3x_2, \\ s_2 &= 1 + 2x_1 + 4x_2, \\ s_3 &= 5 + x_0 + 1.2x_1 + 3.5x_2, \\ s_4 &= 0.7x_1 + 1.1x_2 - 6.4x_3 + x_4 + x_5. \end{aligned}$$

噪声：

$$y = s + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, (\rho \cdot \sigma_s)^2), \quad \sigma_s = \text{Std}(s).$$


数据集	ρ	特征	意图
y1	0	x_1, x_2	无噪声理想线性
y2	0.25	x_1, x_2 + 16 个无关特征	有噪声 + 变量选择
y3	0.15	x_0, x_1, x_2	无多重共线性
y4	0.28	$x_1 \sim x_5$ + 16 个无关特征	多重共线性

默认：n = 80，测试比例 30%，重复 25 次。

6. 实验一：模拟数据 EDA（逐图解读）



脚本：experiments/01_simulated_eda.py
目录：outputs/figures/01_eda/

6.1 特征相关矩阵



解读： x_4 与 x_1 、 x_2 ，以及 x_5 与 x_1 、 x_4 应呈强相关，这是多重共线性来源； x_3 相对独立。


6.2 VIF: 无共线 vs 有共线




解读: y3 的 VIF 接近 1; y4 中 x_4 、 x_5 等 VIF 极高 (对数轴)。虚线对应经验阈值 5 与 10。

6.3 三维散点与二维线性关系


y1 三维散点




y2 三维散点




y1 线性关系 x1-y



y2 线性关系 x1-y




y2 线性关系 x2-y



解读:

- y1 无噪声: 点几乎落在平面/直线上。
- y2 有噪声: 仍有清晰上升趋势, 点带散布。
- x_2-y 斜率应大于 x_1-y (真值系数 $4 > 2$) 。

6.4 y4 配对图



解读： 对角线为分布，非对角为两两散点，可同时看到共线结构与对 y4 的关系。


7. 实验二：四算法对比（逐图解读）

脚本：experiments/02_model_comparison.py


目录：outputs/figures/02_sim_models/

7.1 指标柱状图


y1_no_noise 指标对比




y2_noisy 指标对比



y3_no_multicollinearity 指标对比






解读：


数据	读图结论
y1	四模型 $R^2 \approx 1$ ，误差 ≈ 0
y2	Lasso/LARS 优于 OLS（筛掉无关特征）
y3	四模型接近且都很高
y4	Lasso/LARS（及常 Ridge）优于 OLS

7.2 真实值 vs 预测值




解读：点越贴近对角线越好。

7.3 测试曲线



解读：分面对比各模型与真实曲线的贴合。

7.4 残差诊断





解读：左图残差应在 0 附近随机散布；右图直方图近似对称。

7.5 系数对比 (真值 vs 估计)




解读： 深色为真值，青色为估计。y4 共线下 OLS 易偏离，Ridge 收缩，Lasso/LARS 更稀疏。

7.6 系数稳定性



解读： 箱子越短越稳；共线下 OLS 通常最散。

7.7 Ridge 路径



解读：横轴 α (对数)，纵轴 CV-MSE；虚线为最优 α_0 。

8. 实验三：LARS 稳定性 (逐图解读)


脚本：experiments/03_lars_stability.py



目录：outputs/figures/03_lars_stability/

每次划分：CV 选 LARS 的非零个数 k ，再对比

全变量 OLS vs 仅 LARS 入选变量后的 OLS.


8.1 入选矩阵与频率






解读： 行间图案越一致越稳定；相关变量频率应高，noise* 应低。y4 中 $x_1/x_4/x_5$ 可能互换。

8.2 选择前后指标






解读： 若选择后 R^2 升、RMSE/MAE 降，说明剔除无关/冗余变量提升了泛化。

9. 实验四：Boston EDA（逐图解读）

脚本：experiments/04_boston_eda.py
目录：outputs/figures/04_boston_eda/

符号	含义
CRIM	人均犯罪率
RM	平均房间数
LSTAT	低收入占比
PTRATIO	师生比
MEDV	房价中位数（目标）


9.1 分布



解读： 看偏态、离散与二值特征。

9.2 相关

Boston 特征相关热力图




各特征与房价相关度




解读：通常 LSTAT 与 MEDV 负相关，RM 与 MEDV 正相关。

9.3 关键散点



解读：验证主要线性趋势是否成立。

9.4 封顶处理



解读：原始 MEDV 在 50 处封顶；实验去掉 MEDV = 50 的样本。


预处理：缺失检查 → 去封顶 → 按 $|\text{corr}|$ 筛选 → 标准化。

10. 实验五：Boston 建模（逐图解读）

脚本：experiments/05_boston_modeling.py


目录：outputs/figures/05_boston_models/

10.1 指标对比





解读： 比较 R^2 、RMSE、MAE；结合重复实验看稳定性。




10.2 真实 vs 预测



解读： 点云应沿对角线；高端房价可能系统性低估。


10.3 测试曲线：总览 + 分模型






解读： series.png 为四分面总览；series_*.png 为各模型单独与真实值对比（阴影为偏差）。

10.4 残差




解读： 若呈喇叭形或弯曲，提示异方差或非线性。


10.5 系数




Boston • Ridge 系数




Boston • Lasso 系数





解读：标准化后可比相对重要性；Lasso/LARS 接近 0 表示被剔除。

10.6 Ridge 路径



解读：最优 α 在 CV-MSE 最低处。

11. 项目结构与运行

```
linear_regression_lab/  
├─ main.py / config.py / requirements.txt / README.md  
├─ docs/公式手册.html          # 浏览器看公式（推荐）  
├─ data/ models/ utils/ experiments/  
└─ outputs/figures|reports|data/
```

```
pip install -r requirements.txt  
python main.py  
python main.py --only 01,02,03  
python main.py --only 04,05
```

Windows 可双击 run.bat。

sklearn≥1.2 已移除 load_boston，本项目自动下载并缓存到 outputs/data/boston.csv。

12. 结论要点

1. **y1**：无噪声，OLS 已近乎完美。
2. **y2**：无关特征下 Lasso/LARS 测试误差更低。
3. **y3**：无共线，四模型接近。
4. **y4**：高 VIF；Ridge/Lasso/LARS 更稳。
5. **LARS 稳定性**：相关变量频率高；共线下存在变量互换；选择后常降 RMSE。
6. **Boston**：LSTAT、RM 等关键；分模型曲线便于细看局部差异。

公式速查

$$\hat{\beta}_{\text{OLS}} = (X^{\top}X)^{-1}X^{\top}y,$$

$$\hat{\beta}_{\text{Ridge}} = (X^{\top}X + \alpha I)^{-1}X^{\top}y,$$

$$\hat{\beta}_{\text{Lasso}} = \arg \min_{\beta} \|y - X\beta\|_2^2 + \alpha \|\beta\|_1,$$

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2},$$

$$\text{MSE} = \frac{1}{m} \sum_i (y_i - \hat{y}_i)^2, \quad \text{RMSE} = \sqrt{\text{MSE}}, \quad \text{MAE} = \frac{1}{m} \sum_i |y_i - \hat{y}_i|,$$

$$\text{VIF}_j = \frac{1}{1 - R_j^2}.$$

参考文献

1. 课程实验要求 PDF
2. Hastie, Tibshirani, Friedman. *The Elements of Statistical Learning*
3. Efron et al. Least Angle Regression. *Annals of Statistics*, 2004
4. scikit-learn: Linear Models